

Projeto 1: Regressão com MLP e Estudo de Ablação

Disciplina: Introdução às Redes Neurais Artificiais

Autor: Henrique Crepaldi (RA: 120410)

Código Reprodutível em PyTorch:

<https://github.com/HCrepaldi/Introduction-to-Artificial-Neural-Networks>

1. Configuração Experimental e Reprodutibilidade

1.1. Partição dos Dados e Pré-processamento

O conjunto de dados fornecido possui 300 pares ordenados (x, y) que descrevem uma função não linear contínua com componentes oscilatórias e ruído estocástico. A partição foi executada respeitando estritamente a proporção de **10% para treino (30 amostras)**, **10% para validação (30 amostras)** e **80% para teste (240 amostras)**, com semente pseudoaleatória fixada ($Seed = 42$) para assegurar reprodutibilidade.

Dada a extrema escassez de dados para aprendizado (apenas 30 pontos de suporte), os dados de entrada $x \in [0, 10]$ foram preservados em sua escala original e manipulados em precisão de ponto flutuante de 32 bits (`torch.float32`). Optou-se por não aplicar normalização com vazamento, mantendo o particionamento isolado antes de qualquer cálculo de estatísticas amostrais.

1.2. Definição e Otimização Empírica do Modelo Baseline (Vanilla)

O modelo *baseline* foi construído como uma rede MLP sem o emprego de métodos adaptativos (Adam, RMSprop) e sem termos de aceleração ($momentum = 0.0$) ou penalidades, conforme restrições do projeto.

Durante a fase de exploração empírica, foram avaliadas variações de profundidade (1 a 3 camadas ocultas), largura (32 a 128 neurônios) e funções de ativação. Constatou-se que a função Tanh apresentou maior capacidade de interpolação suave em comparação à ReLU para essa curva contínua. Em virtude do tamanho reduzido do conjunto de treino (30 amostras), o tamanho do lote (*batch size*) foi definido como 10, gerando 3 atualizações de gradiente por época e garantindo estocasticidade no processo. A Tabela 1 sintetiza as configurações exploradas e a topologia final estabelecida para o *baseline*.

Table 1: Espaço amostrado e configuração final da MLP Baseline (Vanilla).

Hiperparâmetro	Valores Explorados	Configuração Escolhida (Vanilla)
Topologia das Camadas	[1, 2 e 3 camadas; [32, 64, 128] neurônios]	Entrada(1) → Densa(64) → Densa(64) → Saída(1)
Função de Ativação	ReLU, LeakyReLU, Tanh	Tanh
Otimizador	SGD Padrão (momentum = 0.0)	SGD ($\eta = 0.01$)
Tamanho do Lote	5, 10, 15, 30 (Full Batch)	10 (3 lotes por época)
Função de Custo	Erro Quadrático Médio (MSE)	MSELoss
Critério de Parada	Número fixo de épocas com estabilidade	500 épocas (com <i>Gradient Clipping</i> = 1.0)
Semente Aleatória	Controle determinístico global	Seed = 42

2. Dinâmica de Treinamento e Convergência (Baseline vs. Modificados)

O treinamento foi conduzido ao longo de 500 épocas. Para evitar instabilidades numéricas e explosão de gradientes decorrentes do acúmulo de velocidades nos modelos com *momentum*, utilizou-se recorte de norma de gradiente (*gradient clipping* com norma máxima 1.0). A Figura 1 apresenta a evolução da função de custo no conjunto de validação ao longo do treinamento.

Análise Crítica da Dinâmica de Convergência:




Figure 1: Evolução da Perda (MSE) no conjunto de validação para o Baseline e modelos aditivados.

- **Estabilidade do SGD:** O SGD puro sem momentum exibiu uma trajetória de convergência lenta e monotônica, estacionando em um patamar de erro médio sem conseguir explorar vales mais profundos da superfície de perda.
- **Comportamento do Momentum:** A inclusão do termo $\beta = 0.9$ introduziu oscilações nas primeiras 100 épocas (visíveis pelos picos transitórios na curva laranja), mas viabilizou o alcance de perdas instantâneas menores na validação (≈ 0.48) em comparação aos demais modelos estáticos.
- **Efeito dos Regularizadores (L1, L2 e Dropout):** As curvas de L1 e L2 acompanharam quase perfeitamente a trajetória do baseline vanilla, indicando que, na presença de poucos dados e baixa magnitude de pesos, a penalização teve efeito marginal na perda de validação. O Dropout induziu maior variabilidade devido à desativação estocástica das unidades.

3. Estudo de Ablação e Desempenho no Conjunto de Teste

Mantendo rigorosamente fixa a arquitetura definida na Tabela 1, realizou-se o estudo de ablação avaliando isoladamente cada técnica no conjunto de teste independente (80% dos dados, correspondendo a 240 observações). As métricas MAE, MSE, RMSE e R^2 obtidas constam na Tabela 2.

Table 2: Resultados do Estudo de Ablação no Conjunto de Teste (80% dos dados).

Modelo / Variação	MAE	MSE	RMSE	R^2
Baseline Vanilla (SGD sem momentum)	0.5987	0.5411	0.7356	-0.0465
Baseline + Momentum ($\beta = 0.9$)	0.5798	0.5121	0.7156	0.0096
Baseline + Regularização L2 ($\lambda = 10^{-3}$)	0.5988	0.5411	0.7356	-0.0464
Baseline + Regularização L1 ($\lambda = 10^{-4}$)	0.5987	0.5411	0.7356	-0.0463
Baseline + Dropout ($p = 0.05$)	0.6012	0.5467	0.7394	-0.0572

A Figura 2 ilustra o ajuste da curva predita pelo *baseline* e pelo modelo com *momentum* sobreposta a todos os dados do problema.

4. Discussão e Lições Aprendidas

- **Impacto da Amostragem Severa (10% de Treino):** Com apenas 30 pontos para mapear um intervalo contínuo de comprimento 10 contendo oscilações de alta frequência, a rede neural




Figure 2: Comparação do ajuste não linear: pontos de treino (10%), teste (80%) e predições dos modelos.

enfrentou um dilema clássico de subajuste (*underfitting*) das oscilações rápidas, aprendendo preferencialmente a tendência de baixa frequência da série. Isso explica o R^2 levemente negativo do *baseline* (-0.0465), cujo desempenho foi comparável à predição pela média amostral.

- O Papel Decisivo do Momentum:** O modelo com *momentum* foi o único capaz de alcançar um coeficiente de determinação positivo ($R^2 = +0.0096$) e reduzir o MSE de teste para 0.5121. Conforme observado na Figura 2, o acúmulo de velocidade permitiu que a curva laranja flexionasse de maneira mais acentuada para capturar o vale entre $x = 2$ e $x = 4$, região onde o SGD puro suavizou em demasia.
- Atuação de L1, L2 e Dropout no Cenário de Subajuste:** Técnicas de regularização como L2, L1 e Dropout têm como finalidade primordial conter o sobreajuste (*overfitting*). Como o gargalo deste experimento decorreu da dificuldade do otimizador em aprender as variações rápidas da função (subajuste), a inserção de Dropout ($p = 0.05$) reduziu ainda mais a capacidade efetiva da rede, elevando o MSE para 0.5467. Já L1 e L2 preservaram métricas idênticas ao baseline, demonstrando que os pesos sinápticos não atingiram magnitudes excessivas que justificassem contração via penalidade.
- Estabilidade Numérica:** A ocorrência inicial de instabilidade com o SGD com momentum ressaltou a importância do controle de gradientes (*gradient clipping*) em problemas onde o passo efetivo do otimizador é amplificado pelo fator $\frac{1}{1-\beta}$.